BrickGPT：通过 ICL 使用 4×4 新零件的实验记录

实验目的：保持 BrickGPT 权重不变，仅通过上下文示例和任务描述，观察模型能否在生成时使用原零件库之外的 4×4 积木。

一、实验设计

共同设置

主指标是**最终输出中是否出现模型生成的 4×4 积木**，包括未完成的输出；是否正常结束、结构是否连通另行记录。完整椅子任务不要求与某个参考结构完全一样。

示例中的 4×4 由同层、相邻的小积木合并得到。后续椅子实验还重新检查了搭建顺序，保证合并前后形状不变，并且每一步都能接到已放置的结构。没有通过预填 4×4 或事后合并输出来提高使用率。实验未验证物理稳定性。

本文按四批已完成的实验分别汇总，共 453 次。调整计划前额外完成的 33 次 2-shot / 10-shot 试跑，以及已中止的多尺寸试验，不计入下表。

A. 初步上下文探索：63 次

任务包括生成椅子、生成桌子，以及把一个小积木结构改写为使用更大积木的结构。主要比较以下上下文：

上下文设计	提供给模型的内容	次数
原零件列表对照	仅给物体描述，提示词仍列出原零件	6
新零件文字说明	列出 4×4，说明其尺寸和替换相邻小块的用途	6
完整模型示例	原物体描述＋含 4×4 的完整搭建顺序；分别给 1、2、5、10 个示例	24
完整结构替换示例	展示同一物体合并前后的两套积木序列，给 2 个示例	6
多轮对话示例	用真实的“用户描述—助手搭建顺序”对话提供 2 或 5 个示例	6
局部替换示例	展示两块 2×4、四块 2×2 等如何变成一块 4×4，给 3 个示例	3
官方基础模板对照	使用官方基础指令，只加 4×4；比较不加示例和加 2 个示例	6
官方 zero-shot / few-shot 模板	使用官方的地面起步、只输出积木等说明；few-shot 组放入 2 个含 4×4 的示例	6

B. 替换、数量约束和挖空填补：240 次

设计 12 个小任务，每个任务测试 10 种提示配置，各重复 2 次。任务包含：

- **小块替换**：将多个小积木改为大积木，保持原来的占据空间。
- **数量约束**：要求用不超过 1 或 2 块积木搭出指定的小结构。
- **挖空填补**：给定已有结构，挖去角落、中央或两个区域，让模型补齐；部分任务同时限制新增积木数量。
- **描述生成**：只描述一个简单方形结构，让模型从零生成。

这批示例以简单几何结构为主，与测试任务对应。比较仅列新零件、增加文字说明、给 1 / 2 / 5 / 10 个完整示例、给 2 个替换前后配对示例，以及给 2 轮对话示例。另外对无示例和 2 示例两种配置提高采样随机性。

这批早期任务要求精确保留或补齐目标形状；后续椅子实验已取消这一要求。

C. 原描述＋合并后的椅子搭建顺序：45 次

从现有数据选出 10 把椅子，将可合并的小积木改为 4×4，再修正和检查搭建顺序。上下文只提供“搭这个物体”的原描述，以及修改后的完整序列，**不展示修改前的序列，也不解释替换过程**。

分别给 2、5、10 个示例，每组做 15 次：3 个椅子描述，每个描述重复 5 次。三组使用同一组示例的前 2、5、10 个，任务保持一致。

D. 五示例提示策略比较：105 次

根据后续调整，以下各组统一只给 **5 个示例，每组 15 次**。其中“局部任务—完整椅子”分成两组，加上一组对照，共 7 组。

分组	上下文如何设计	最后要求模型做什么
地面起步对照	复用真实椅子的合并后序列；明确提醒从地面开始搭新物体，不续写示例	从零生成完整椅子
替换过程＋语言解释	给“小块序列 → 为什么能合并 →4×4 序列”，说明同层、相邻、空间不变及数量减少	把示例规则用于完整椅子
完整椅子合并＋减少积木	给整把椅子的合并前后序列，指出哪些步骤合并、减少多少块以及如何调整顺序	尽量用更少积木生成椅子
明确要求 4×4 座面	示例描述明确关联“4×4”和“座面”，输出给出对应的椅子序列	用 4×4 做座面，生成完整椅子
给定椅腿后续搭	给旧零件组成的四腿和平台，示例展示在其上添加 4×4 座面与靠背	保留给定部分，继续搭椅子
局部方形座面测试	给多个小块合并为一块 4×4 的解释和结果	用更少积木搭单层方形座面
局部规则迁移到完整椅子	5 个示例交替放置：局部座面、完整椅子、局部座面、完整椅子、局部座面	将局部合并规则用于完整椅子

例如，局部解释会明确写出：“两块同层且相邻的 2×4 正好铺满一个 4×4 区域，可以改为一块 4×4，位置和占据空间不变，数量从 2 减少到 1。”

“迁移”组只改变上下文组合，不训练模型，也不让模型记住前一组的推理结果。

二、实验结果

A. 初步上下文探索

63 次实验均未在最终输出中使用 4×4。增加完整示例数量、改为多轮对话、展示替换前后关系或采用官方模板，都没有观察到新零件使用。

B. 替换、数量约束和挖空填补

提示配置	实验次数	最终使用 4×4
仅列出新零件	24	0
文字说明，无示例	24	0
1 个完整示例	24	2
2 个完整示例	24	1
5 个完整示例	24	1
10 个完整示例	24	1
2 个替换前后配对示例	24	0
2 轮对话示例	24	1
无示例，提高随机性	24	1
2 个示例，提高随机性	24	4
合计	**240**	**11（4.6%）**

这 11 次中，6 次来自替换 / 数量约束任务，5 次来自挖空任务。**没有一次同时满足完整任务要求。**例如，有的输出补齐了缺口，却在其他位置继续增加积木，或超过了数量限制。

因此，这批实验说明模型偶尔可以输出 4×4，但还不能说明它能准确执行替换、控制数量或完成填补。提高随机性的 2 示例组出现次数最多，但样本较少，不能据此认定该配置稳定更好。

C. 原描述＋合并后的椅子搭建顺序

示例数量	实验次数	最终使用 4×4	累计连通性回退
2	15	0	45
5	15	0	41
10	15	0	39

增加示例数量没有带来 4×4 使用。不少输出从较高位置开始或出现不连通部分，说明除了新零件使用，模型本身也存在任务跟随问题。

D. 五示例提示策略比较

分组	实验次数	最终使用 4×4	累计连通性回退
地面起步对照	15	0	41
替换过程＋语言解释	15	0	32
完整椅子合并＋减少积木	15	0	36
明确要求 4×4 座面	15	0	31
给定椅腿后续搭	15	0	29
局部方形座面测试	15	**1**	23
局部规则迁移到完整椅子	15	0	26
合计	**105**	**1（1.0%）**	**218**

回退指输出不连通后，删除后段并重新生成；表中为每组 15 次的累计值，不是物理稳定性回退。

唯一出现 4×4 的局部座面案例，实际生成了远大于目标的结构，最终不连通，并在达到时间上限后结束。**它满足“输出过新零件”，但不满足“正确完成局部任务”。**该批也没有正常结束、连通且包含 4×4 的输出。

在这一轮，加入语言解释、减少积木的要求、直接指定 4×4 座面、给定支撑前缀以及混合局部与完整示例，都没有让完整椅子输出使用 4×4。

结果判断

在目前测试的上下文和任务设置下，尚未观察到后两批完整椅子任务使用 4×4。简单或受限任务中偶尔出现新尺寸，但位置、数量和任务完成情况仍不理想。现有结果不足以支持“仅靠这些 ICL 示例即可稳定扩展零件库”，也不能据此断言所有 ICL 设计都不可行。

完整输入、逐次输出图片和回退记录保留在原实验目录。四批对应目录依次为 `icl_4x4`、`icl_overnight`、`icl_chairs`、`icl_strategies`；最新 105 次的实际输入、输出指标和图片完整性检查已通过。